

Modelo Aditivo e Híbrido

Vitor Oliveira Ropke



Novembro de 2024

Prophet

- Baseado no modelo aditivo
- Funciona melhor com dados sazonais
- Trata dados faltantes, mudanças de padrões e outliers

Componentes

$$y(t) = g(t) + s(t) + h(t) + \epsilon_t \quad (1)$$

- $y(t)$: Função resultante.
- $g(t)$: Função de tendência.
- $s(t)$: Função de sazonalidade.
- $h(t)$: Função de feriados.
- ϵ_t : Mudanças idiossincráticas.

Componentes

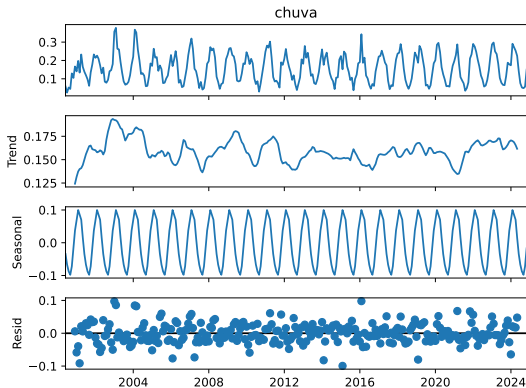


Figura 1: Componentes de um Modelo Aditivo

Tendência

A incerteza da previsão é definida através da seguinte equação:

$$\lambda = \frac{1}{S} \sum_{j=1}^S |\delta_j| \quad (2)$$

- λ : Incerteza da previsão.
- S : Número de mudanças na tendência.
- $|\delta_j|$: Valor da mudança na tendência.

Tendência




Figura 2: Tendência em uma Série Temporal

Sazonalidade

A sazonalidade é feita a partir da série de Fourier, dada na seguinte equação:

$$s(t) = \sum_{n=1}^N \left(a_n \cos \left(\frac{2\pi nt}{P} \right) + b_n \sin \left(\frac{2\pi nt}{P} \right) \right) \quad (3)$$

- N : Número de termos de Fourier (filtro passa-baixa).
- P : Regularidade do período em número de dias.

Sazonalidade

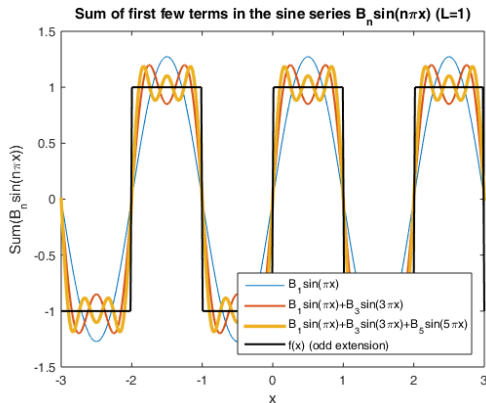


Figura 3: Séries de Fourier

Sazonalidade




Figura 4: Sazonalidade de uma Série Temporal

NeuralProphet

- Além de redes neurais, utiliza outros modelos de *deep learning*
- É uma extensão do Prophet

Componentes

$$\hat{y}(t) = T(t) + S(t) + E(t) + F(t) + A(t) + L(t) \quad (4)$$

- $\hat{y}(t)$: Valores preditos.
- $T(t)$: Função de tendência.
- $S(t)$: Função de sazonalidade.
- $E(t)$: Função de eventos e feriados.
- $F(t)$: Efeitos de regressão para variáveis externas com futuro conhecido.
- $A(t)$: Efeitos de auto-regressão baseados nas observações passadas.
- $L(t)$: Efeitos de regressão para as últimas observações de variáveis exógenas.

Auto-regressão

O cálculo de valores futuros é feito usando a seguinte equação:

$$y_t = c + \sum_{i=1}^{i=p} \theta_i \cdot y_{t-i} + \epsilon_t \quad (5)$$

- y_t : Valor predito.
- p : Número de valores passados.
- θ_i : Coeficiente a direção e magnitude do valor passado i .
- c : Interceptor.
- ϵ_t : Ruído branco.

Auto-regressão




Figura 5: Auto-regressão comparado com valores reais

Regressores defasados (*Lagged Regressors*)

Usado para correlacionar outras variáveis (covariáveis) com o target, seguindo a equação:

$$L(t) = \sum_{x \in \mathbb{X}} L_x(x_{t-1}, x_{t-2}, \dots, x_{t-p}) \quad (6)$$

- $L(t)$: Valor defasado.
- \mathbb{X} : Conjunto das covariáveis.
- x : Valor da covariável.

Regressores defasados (*Lagged Regressors*)




Figura 6: Covariável e target

Regressores do futuro

Covariáveis com futuro conhecido, seguindo a equação:

$$F(t) = \sum_{f \in \mathbb{F}} F_f^*(t) \quad (7)$$

- $F(t)$: Efeito de todos os regressores.
- \mathbb{F} : Conjunto das covariáveis com futuro conhecido.
- f : Regressor.

Regressores do futuro




Figura 7: Covariável e target

ACABOU-SE!!!

